# Иногозначная классификация TEKCTOB

Нейросети для анализа текстов

## Задачи классификации

## Бинарная классификация (binary classification)

- Два класса объектов
- Объект может принадлежать только одному классу
- Положительная или отрицательная тональность в IMDB или YELP


#### Многоклассовая классификация (multiclass classification):

- Несколько классов объектов
- Объект может принадлежать только одному классу
- Темы новостей AG News

## Многозначная классификация (multilabel classification)

- Несколько классов объектов
- Каждый объект может принадлежать нескольким классам
- Токсичные комментарии (<a href="https://www.kaggle.com/c/jigsaw-toxic-comment-classification-challenge">https://www.kaggle.com/c/jigsaw-toxic-comment-classification-challenge</a>)

## Соревнования по определению токсичности комментариев



# Классы токсичности комментариев

Название класса на английском	Название класса на русском
toxic	токсичный
severe_toxic	существенно токсичный
obscene	обсценная лексика
threat	угроза
insult	оскорбление
identity_hate	личная ненависть

# Формат данных

Комментарий	toxic	severe_toxic	obscene	threat	insult	identity_ hate
Hi! I am back again! Last warning! Stop undoing my edits or die!	1	0	0	1	0	0
Would you both shut up, you don't run wikipedia, especially a stupid kid.	1	0	0	0	1	0
COCKSUCKER BEFORE YOU PISS AROUND ON MY WORK	1	1	1	0	1	0
Your vandalism to the Matt Shirvington article has been reverted. Please don't do it again, or you will be banned.	0	0	0	0	0	0

## Архитектура нейронной сети

```
model = Sequential()
model.add(Embedding(10000, 128, input_length=50))
model.add(SpatialDropout1D(0.5))
model.add(LSTM(40, return_sequences=True))
model.add(LSTM(40))
model.add(Dense(6, activation='sigmoid'))
```

## Пространственный Dropout

I	0.1	0.8	-0.5	0.3
was	-0.2	0.15	0.99	0.01
very	0.75	-0.1	-0.17	0.64
touched	-0.1	-0.2	0.23	0.13



1	0.1	0.8	-0.5	0.3
was	0.0	0.0	0.0	0.0
very	0.75	-0.1	-0.17	0.64
touched	-0.1	-0.2	0.23	0.13

Исходные данные

SpatialDropout

Jonathan Tompson, Ross Goroshin, Arjun Jain, Yann LeCun, Christoph Bregler. Efficient Object Localization Using Convolutional Networks. 2015. https://arxiv.org/pdf/1411.4280.pdf

## Функция ошибки

## Результаты работы сети

```
comment = "X-BOX 360 SUKCS BIG BUMM AND LIKES IT UP THE ASS"
sequence = tokenizer.texts to sequences([comment])
data = pad sequences(sequence, maxlen=50)
result = model.predict(data)
array([[0.93577635, 0.05646498, 0.63453263, 0.02494773,
0.59398603, 0.07905076]], dtype=float32)
Правильный ответ:
[1,0,1,0,1,0]
```

## Функции активации и ошибки для задач классификации

Задача классификации	Функция активации выходного слоя	Функция ошибки
Бинарная классификация (binary classification)	sigmoid	binary_crossentropy
Многоклассовая классификация (multiclass classification)	softmax	categorical_crossentropy
Многозначная классификация (multilabel classification)	sigmoid	binary_crossentropy